Avance 2: exploración y preparación de datos

Proyecto grupal CA0204 — Cine en datos

José Gabriel Coronel Cascante — C5E486
Gabriel Jop Baltodano — C5G338
Lemuel Méndez Hidalgo — C24750
Andrés Salas Acuña — C37104
Jean Carlo Sanabria Martínez — C37241

2026-01-01

Base de datos

El dataset que se plantea usar en el proyecto es el siguiente: Top 1000 IMDB movies.

Extraído de la base de datasets de la página web Kaggle. Los datos se recopilaron a través del método *web scraping* desde la página web oficial pública de IMDbd usando *Selenium*; una herramienta de código abierto que sirve para entre otras cosas, la extracción de datos en navegadores web.

Este dataset incluye las 1000 mejores peliculas de la historia, a nivel global; usando como periodo de cobertura desde el año 1975 hasta 2022 (última actualización), según la página dedicada al cine y la televisión IMDb (Internet Movie Database), donde se incluye entre otras cosas sinopsis de peliculas, teasers, recomendaciones, reseñas y calificaciones tanto del público *(IMDb rating)* como de la crítica especializada *(Meta score)*.

Objetivo del Proyecto

El objetivo del presente trabajo es analizar el conjunto de datos de las 1000 películas mejor calificadas en IMDb, para observar que características se relacionan con calificaciones positivas de parte del público, las críticas especializadas, y el éxito en general. La pregunta central es: ¿Qué hace que una película sea un éxito en taquilla, sea amada por el público y al mismo tiempo alabada por la crítica?. Para responder tal preguntá se buscará construir una "fórmula ganadora" que exponga las principales conclusiones del proyecto.

Lectura de Datos

Primero, se importan las librerías necesarias. En este caso, `readr` para la lectura de los datos y `magrittr, dplyr` para la manipulación de estos.

Luego, importamos el dataset a partir de un archivo `.csv`, mediante la librería `readr`

Manipulación y Presentación de Datos

El `dataframe` contiene diferentes características de las películas, muestra un link al poster, el título, año de lanzamiento, certificado de contenidos (clasificación por edades), duración, géneros, calificación IMDb (de 0 a 10), descripción, puntuación por críticas (de 0 a 100), director, actores/actrices principales, número de votos e ingresos brutos. Información encontrada mediante la función `df.original %>% glimpse()` y traducido por el equipo

Para empezar, se muestran las características principales del `dataframe` orginal, señalando la totalidad de películas, registros, cantidad de variables, distribución de géneros y directores y un rango en años de lanzamiento

Característica	Valor
Número de películas	1000
Número de registros	1000
Número de variables	16
Número de géneros	21
Número de directores	548
Rango de años	1920 - 2020

Géneros más comunes

Género	Número de películas
Drama	724
Comedy	233
Crime	209
Adventure	196
Action	189
Thriller	137
Romance	125
Biography	109

Nota: Una misma película puede pertenecer a más de un género, por lo que puede ser contabilizada en varias categorías.

Directores con mayor lanzamiento de películas

Director	Número de películas
Alfred Hitchcock	14
Steven Spielberg	13
Hayao Miyazaki	11
Akira Kurosawa	10
Martin Scorsese	10
Billy Wilder	9
Stanley Kubrick	9
Woody Allen	9

Seguidamente, se inspecciona el `dataframe` brevemente, mostrando una selección de datos de las primeras 5 filas y un resumen de los contenidos y sus calificaciones.

Película	Año	Género	Calificación IMDb	Metascore
The Shawshank Redemption	1994	Drama	9.3	80

Película	Año	Género	Calificación IMDb	Metascore
The Godfather	1972	Crime, Drama	9.2	100
The Dark Knight	2008	Action, Crime, Drama	9.0	84
The Godfather: Part II	1974	Crime, Drama	9.0	90
12 Angry Men	1957	Crime, Drama	9.0	96

Nota: la tabla anterior no representa el total de las variables del dataset debido al tamaño se optó por mostrar solo las cinco principales columnas. Las otras variables incluyen datos como: el director, las principales estrellas, taquilla, la descripción, duración, certificación, etc.

Luego, se genera y modifica otro `dataframe` a partir de `df.original`, con el fin de facilitar nuestro análisis.

1. Se elimina la columna `poster`

La variable `Poster_Link` contiene únicamente el enlace a la imagen del póster de cada película. Por lo que no aporta un valor cuantitativo o categórico relevante para los análisis planteados en este avance

2. Se crea una columna `id` según el rating

Se agrega una variable `id` con valores consecutivos para identificar de manera única cada fila del `dataframe`. Se presenta de mayor a menor calificación IMDb. De esta forma, el `id` permite ubicar y referenciar con mayor facilidad cada observación durante la manipulación de los datos.

3. Se ajustan las clases de datos

Las variables `IMDB_Rating`, `Meta_score`, `Runtime` y `Gross` representan datos numéricos y serán utilizadas posteriormente para realizar operaciones estadísticas, como promedios y correlaciones. Por ello, se convierten explícitamente a clase de datos `numeric` para el rating y no perder decimales e `integer` para los demás, pues no contienen decimales y se ahorra espacio en la memoria, con el fin de garantizar que R las reconozca como variables cuantitativas.

Una Primera Exploración de los Datos

Cantidad de observaciones `NA` por cada columna de `df`.

	NA por columna
Certificado	101
Meta_score	157
Ingresos Brutos	169

Exploramos algunos de los promedios de calificaciones entre el público y la crítica, así cómo su correlación. Además incluimos los promedios de duración y de taquilla:

Indicador	valor
Promedio IMBD	7.95
Promedio Metascore	7.80
Correlacion IMDB vs Metascore	0.27
Promedio de duración (en horas)	2.05
Promedio de taquilla (en millones de $)	68.03