Grupo_1_HerramientasDatosI_2026

Universidad de Costa Rica — CA0204 Herramientas de Datos I — Cine en datos

José Gabriel Coronel Cascante — C5E486
Gabriel Jop Baltodano — C5G338
Lemuel Méndez Hidalgo — C24750
Andrés Salas Acuña — C37104
Jean Carlo Sanabria Martínez — C37241

6 de noviembre de 2026

Introducción

El dataset que se plantea usar en el proyecto es el siguiente: Top 1000 IMDB movies.

Extraído de la base de datasets de la página web Kaggle. Los datos se recopilaron a través del método *web scraping* desde la página web oficial pública de IMDbd usando *Selenium*; una herramienta de código abierto que sirve para entre otras cosas, la extracción de datos en navegadores web.

Este dataset incluye las 1000 mejores peliculas de la historia, a nivel global; usando como periodo de cobertura desde el año 1975 hasta 2022 (última actualización), según la página dedicada al cine y la televisión IMDb (Internet Movie Database), donde se incluye entre otras cosas sinopsis de peliculas, teasers, recomendaciones, reseñas y calificaciones tanto del público *(IMDb rating)* como de la crítica especializada *(Meta score)*.

Objetivo general

Identificar qué características de las películas (género, duración, década de lanzamiento, etc.) se asocian con el éxito en la calificación del público, la valoración de la crítica y la taquilla, mediante un análisis descriptivo y de correlación de las 1000 películas mejor calificadas en IMDb.

Metodología

Datos

Primero, se importan las librerías necesarias. En este caso, `readr` para la lectura de los datos y `magrittr, dplyr` para la manipulación de estos.

Luego, importamos el dataset a partir de un archivo `.csv`, mediante la librería `readr`

El `dataframe` contiene diferentes características de las películas, muestra un link al poster, el título, año de lanzamiento, certificado de contenidos (clasificación por edades), duración, géneros, calificación IMDb (de 0 a 10), descripción, puntuación por críticas (de 0 a 100), director, actores/actrices principales, número de votos e ingresos brutos. Información encontrada mediante la función `df.original %>% glimpse()` y traducido por el equipo

Limpieza y preparación

Luego, se genera y modifica otro `dataframe` a partir de `df.original`, con el fin de facilitar nuestro análisis.

1. Se elimina la columna `poster`

La variable `Poster_Link` contiene únicamente el enlace a la imagen del póster de cada película. Por lo que no aporta un valor cuantitativo o categórico relevante para los análisis planteados en este avance

2. Se crea una columna `id` según el rating

Se agrega una variable `id` con valores consecutivos para identificar de manera única cada fila del `dataframe`. Se presenta de mayor a menor calificación IMDb. De esta forma, el `id` permite ubicar y referenciar con mayor facilidad cada observación durante la manipulación de los datos.

3. Se ajustan las clases de datos

Las variables `IMDB_Rating`, `Meta_score`, `Runtime` y `Gross` representan datos numéricos y serán utilizadas posteriormente para realizar operaciones estadísticas, como promedios y correlaciones. Por ello, se convierten explícitamente a clase de datos `numeric` para el rating y no perder decimales e `integer` para los demás, pues no contienen decimales y se ahorra espacio en la memoria, con el fin de garantizar que R las reconozca como variables cuantitativas.

Técnicas y herramientas

Resultados

Análisis exploratorio

Para empezar, se muestran las características principales del `dataframe` orginal, señalando la totalidad de películas, registros, cantidad de variables, distribución de géneros y directores y un rango en años de lanzamiento

Característica	Valor
Número de películas	1000
Número de registros	1000
Número de variables	16
Número de géneros	21
Número de directores	548
Rango de años	1920 - 2020

Géneros más comunes

Género	Número de películas
Drama	724
Comedy	233
Crime	209
Adventure	196
Action	189
Thriller	137

Género	Número de películas
Romance	125
Biography	109

Nota: Una misma película puede pertenecer a más de un género, por lo que puede ser contabilizada en varias categorías.

Directores con mayor lanzamiento de películas en el conjunto estudiado

Director	Número de películas
Alfred Hitchcock	14
Steven Spielberg	13
Hayao Miyazaki	11
Akira Kurosawa	10
Martin Scorsese	10
Billy Wilder	9
Stanley Kubrick	9
Woody Allen	9

Seguidamente, se inspecciona el `dataframe` brevemente, mostrando una selección de datos de las primeras 5 filas y un resumen de los contenidos y sus calificaciones.

Película	Año	Género	Calificación IMDb	Metascore
The Shawshank Redemption	1994	Drama	9.3	80
The Godfather	1972	Crime, Drama	9.2	100
The Dark Knight	2008	Action, Crime, Drama	9.0	84
The Godfather: Part II	1974	Crime, Drama	9.0	90
12 Angry Men	1957	Crime, Drama	9.0	96

Nota: la tabla anterior no representa el total de las variables del dataset debido al tamaño se optó por mostrar solo las cinco principales columnas. Las otras variables incluyen datos como: el director, las principales estrellas, taquilla, la descripción, duración, certificación, etc.

Cantidad de observaciones `NA` por cada columna de `df`.

	NA por columna
Certificado	101
Meta_score	157
Ingresos Brutos	169

Exploramos algunos de los promedios de calificaciones entre el público y la crítica, así cómo su correlación. Además incluimos los promedios de duración y de taquilla:

Indicador	valor
Promedio IMBb	7.95
Promedio Metascore	7.80

Indicador	valor
Correlacion IMDB vs Metascore	0.27
Promedio de duración (en horas)	2.05
Promedio de taquilla (en millones de $)	68.03

Resultados de la metodología

Se analizan varios factores que podrían determinar la popularidad o afectar su calificación. Iniciamos analizando la duración y cuales promedios tienen una calificación más alta.

Dicho análisis se ve en este cuadro

Rango	Cantidad	Calificacion_promedio
Menos de 90 min	68	7.94
90-119 min	438	7.89
120-149 min	344	7.96
150-179 min	106	8.10
180 min o más	44	8.10

Como se puede observar, las películas con una duración de dos horas y media o superior (150 minutos o más) parecen tener una calificación superior en promedio. Sin embargo, hay que tomar en cuenta las diferencias de tamaño en los grupos.

El protagonista de una película y quién dirige tal película, constituyen partes importantes de la fórmula ganadora. Por tal razón, se analiza la relación entre el ingreso de una película, su calificación en IMDb, su director y protagonista. Específicamente, se consideran los actores protagonistas y directores cuyas películas en promedio generan las calificaciones más altas o los mayores ingresos. En este caso, *promedio*, se refiere a la media bayesiana con una parámetro de confianza de $k = 4$. Este promedio determina el peso del promedio general, es decir, entre más pequeño sea el grupo analizado, más se ve afectado por el promedio general. Esto para contemplar los promedios artificialmente altos debido una pequeña cantidad de películas asociadas.

Protagonista	Películas	IMDb Promedio Ajustado
Elijah Wood	3	8.312532
Tim Robbins	1	8.217545
Mark Hamill	3	8.198246

Protagonista	Películas	Ingresos Generados Promedio Ajustados
Joe Russo	4	309647301
Daisy Ridley	1	241760246
Daniel Radcliffe	6	210804004

Con respecto al protagonista, se observa que en promedio los actores Elijah Wood, Tim Robbins y Mark Hamill se asocian, en promedio, a las mayores calificaciones en la plataforma IMDb. Por otro lado, son Joe Russo, Daisy Ridley y Daniel Radcliffe quienes están asociados en promedio al mayor éxito comercial.

Director	Películas	IMDb Promedio Ajustado
Christopher Nolan	8	8.290644
Frank Darabont	2	8.281288
Francis Ford Coppola	5	8.198636

Director	Películas	Ingresos Generados Promedio Ajustados
Anthony Russo	4	309647301
J.J. Abrams	3	242187130
James Cameron	5	224486178

Además, se observa que Christopher Nolan, Frank Darabont y Francis Ford Coppola son los directores que en promedio se asocian a una mayor calificación de IMDb. Con respecto al aspecto comercial, Anthony Russo, J. J. Abrams y James Cameron son los directores más exitosos en promedio.

Bibliografía

IMDb. (s.f.). Apolo 13 (1995). Recuperado el 5 de noviembre de 2026, de IMDb

Anexos

Repositorio del proyecto: https://github.com/corgab33/Proyecto-Grupal-CA0204