Grupo_7_HerramientasDatosI_2026

Universidad de Costa Rica — CA0204 Herramientas de Datos I — Cine en datos

José Gabriel Coronel Cascante — C5E486
Gabriel Jop Baltodano — C5G338
Lemuel Méndez Hidalgo — C24750
Andrés Salas Acuña — C37104
Jean Carlo Sanabria Martínez — C37241

6 de noviembre de 2026

Introducción

El cine es una de las formas de entretenimiento y expresión cultural más influyentes a nivel mundial. Gracias a plataformas como IMDb (Internet Movie Database), es posible acceder a grandes volúmenes de información sobre películas, incluyendo sinopsis de películas, teasers, recomendaciones, reseñas y calificaciones tanto del público *(IMDb rating)* como de la crítica especializada *(Meta score)*. Estos datos permiten estudiar qué características comparten las películas mejor valoradas y cómo distintos elementos, como los actores, directores, géneros y las historias narradas, se relacionan con su recepción por parte de las audiencias.

La relevancia de este tema radica en la posibilidad de identificar patrones presentes en las películas más reconocidas y mejor valoradas. El estudio de aspectos como el elenco, la dirección, la distribución de géneros, diferencias entre la opinión del público y la crítica especializada, así como los temas narrativos recurrentes en las tramas, permite comprender mejor las características que predominan en las producciones con mayor reconocimiento. Asimismo, este tipo de análisis constituye un ejemplo práctico de cómo las herramientas de ciencia de datos pueden utilizarse para extraer conocimiento útil a partir de grandes volúmenes de información textual y numérica.

El dataset que se plantea usar en el proyecto es el siguiente: Top 1000 IMDB movies.

Este dataset incluye las 1000 mejores peliculas de la historia, a nivel global; usando como periodo de cobertura desde el año 1920 hasta 2022 (última actualización), según IMDb. Fue extraído de la base de datasets de la página web Kaggle. Los datos se recopilaron a través del método *web scraping* desde la página web oficial pública de IMDbd usando *Selenium*; una herramienta de código abierto que sirve para entre otras cosas, la extracción de datos en navegadores web.

Objetivo general

Identificar qué características de las películas (género, duración, década de lanzamiento, etc.) se asocian con el éxito en la calificación del público, la valoración de la crítica y la taquilla, mediante un análisis descriptivo y de correlación de las 1000 películas mejor calificadas en IMDb.

Metodología

Datos

Primero, se importan las librerías necesarias. En este caso, `readr` para la lectura de los datos y `magrittr, dplyr` para la manipulación de estos.

Luego, importamos el dataset a partir de un archivo `.csv`, mediante la librería `readr`.

El `dataframe` contiene diferentes características de las películas, muestra un link al poster, el título, año de lanzamiento, certificado de contenidos (clasificación por edades), duración, géneros, calificación IMDb (de 0 a 10), descripción, puntuación por críticas (de 0 a 100), director, actores/actrices principales, número de votos e ingresos brutos. Información encontrada mediante la función `df.original %>% glimpse()` y traducido por el equipo.

Limpieza y preparación

Luego, se genera y modifica otro `dataframe` a partir de `df.original`, con el fin de facilitar nuestro análisis.

1. Se elimina la columna `poster`

La variable `Poster_Link` contiene únicamente el enlace a la imagen del póster de cada película. Por lo que no aporta un valor cuantitativo o categórico relevante para los análisis planteados en este avance.

2. Se crea una columna `id` según el rating

Se agrega una variable `id` con valores consecutivos para identificar de manera única cada fila del `dataframe`. Se presenta de mayor a menor calificación IMDb. De esta forma, el `id` permite ubicar y referenciar con mayor facilidad cada observación durante la manipulación de los datos.

3. Se ajustan las clases de datos

Las variables `IMDB_Rating`, `Meta_score`, `Runtime` y `Gross` representan datos numéricos y serán utilizadas posteriormente para realizar operaciones estadísticas, como promedios y correlaciones. Por ello, se convierten explícitamente a clase de datos `numeric` para el rating y no perder decimales e `integer` para los demás, pues no contienen decimales y se ahorra espacio en la memoria, con el fin de garantizar que R las reconozca como variables cuantitativas.

Técnicas y herramientas

Para los análisis se filtra `df` para que solo contenga las observaciones en las que existe cálificación de `Meta_score`, es decir eliminamos las observaciones con `NA`.

Análisis sinópsis:

Para el análisis de la sinópsis empleamos la función `tidytext::unnest_tokens()` para divdidir la columna `Overview` en palabras individuales, usando un `anti_join()` con el tibble `stop_words` para filtar y eliminar artículos que no aportan información relevante de las tramas de las peliculas. Además filtramos por frecuencia de aparición en distintas peliculas, asimismo se crea el tibble `corr.pares` usando la función `widyr::pairwise_cor()`, que toma dos palabras de la lista y calcula la correlación entre las apariciones de ambas palabras en una misma pelicula, es decir, mide la fuerza en la relación de las variables, esto nos pérmitira obtener una mejor aproximación a las témáticas frecuentes que analizar por una sola palabra, además se forman narrativas más completas.

Para extraer los resultados de los análisis creamos las funciones `analizar.palabra` y `analizar.par`, que lee una palabra y un par de palabras, respectivamente, y arroja un tibble que contiene un análisis estadístico con las variables: peliculas, cantidad de peliculas contienen palabra/s; porcentaje,

proporción del total; imdb y meta, que contienen el promedio de calificación de esas peliculas para cada palabra o par.

Apartado análisis género:
Para el análisis de género separamos los elementos de la columna `Genre` en géneros individuales. De una forma muy similar a lo que se hace en sinópsis creamos las funciones `analizar.genero` y `analizar.genero.unico`, cuya única diferencia es que en el segundo para que un género sea contabilizado la coincidencia debe ser total y no parcial. Estas funciones de manera análoga a las de análisis de sinópsis crean un tibble con resumenes estadísticos, de las peliculas que pertenecen a cada género, de forma individual (solo un género) o compuesta cómo se encuentran originalmente en `df.original`.

Resultados

Análisis exploratorio

Para empezar, se muestran las características principales del `dataframe` orginal, señalando la totalidad de películas, registros, cantidad de variables, distribución de géneros y directores y un rango en años de lanzamiento.

Característica	Valor
Número de películas	1000
Número de registros	1000
Número de variables	16
Número de géneros	21
Número de directores	548
Rango de años	1920 - 2020

Géneros más comunes

Género	Número de películas
Drama	724
Comedy	233
Crime	209
Adventure	196
Action	189
Thriller	137
Romance	125
Biography	109

Nota: Una misma película puede pertenecer a más de un género, por lo que puede ser contabilizada en varias categorías.

Directores con mayor lanzamiento de películas en el conjunto estudiado

Director	Número de películas
Alfred Hitchcock	14
Steven Spielberg	13

Director	Número de películas
Hayao Miyazaki	11
Akira Kurosawa	10
Martin Scorsese	10
Billy Wilder	9
Stanley Kubrick	9
Woody Allen	9

Seguidamente, se inspecciona el `dataframe` brevemente, mostrando una selección de datos de las primeras 5 filas y un resumen de los contenidos y sus calificaciones.

Película	Año	Género	Calificación IMDb	Metascore
The Shawshank Redemption	1994	Drama	9.3	80
The Godfather	1972	Crime, Drama	9.2	100
The Dark Knight	2008	Action, Crime, Drama	9.0	84
The Godfather: Part II	1974	Crime, Drama	9.0	90
12 Angry Men	1957	Crime, Drama	9.0	96

Nota: la tabla anterior no representa el total de las variables del dataset debido al tamaño se optó por mostrar solo las cinco principales columnas. Las otras variables incluyen datos como: el director, las principales estrellas, taquilla, la descripción, duración, certificación, etc.

Cantidad de observaciones `NA` por cada columna de `df`.

	NA por columna
Certificado	101
Meta_score	157
Ingresos Brutos	169

Exploramos algunos de los promedios de calificaciones entre el público y la crítica, así cómo su correlación. Además incluimos los promedios de duración y de taquilla:

Indicador	valor
Promedio IMBb	7.95
Promedio Metascore	7.80
Correlacion IMDB vs Metascore	0.27
Promedio de duración (en horas)	2.05
Promedio de taquilla (en millones de $)	68.03

Resultados de la metodología

Se analizan varios factores que podrían determinar la popularidad o afectar su calificación. Iniciamos analizando la duración y cuales promedios tienen una calificación más alta.

Dicho análisis se ve en este cuadro

Rango	Cantidad	Calificacion_promedio
Menos de 90 min	68	7.94
90-119 min	438	7.89
120-149 min	344	7.96
150-179 min	106	8.10
180 min o más	44	8.10

Como se puede observar, las películas con una duración de dos horas y media o superior (150 minutos o más) parecen tener una calificación superior en promedio. Sin embargo, hay que tomar en cuenta las diferencias de tamaño en los grupos.

El protagonista de una película y quién dirige tal película, constituyen partes importantes de la fórmula ganadora. Por tal razón, se analiza la relación entre el ingreso de una película, su calificación en IMDb, su director y protagonista. Específicamente, se consideran los actores protagonistas y directores cuyas películas en promedio generan las calificaciones más altas o los mayores ingresos. En este caso, *promedio*, se refiere a la media bayesiana con una parámetro de confianza de $k = 4$. Este promedio determina el peso del promedio general, es decir, entre más pequeño sea el grupo analizado, más se ve afectado por el promedio general (MetricGate, 2025). Esto para contemplar los promedios artificialmente altos debido una pequeña cantidad de películas asociadas.

Protagonista	Películas	IMDb Promedio Ajustado
Elijah Wood	3	8.312532
Tim Robbins	1	8.217545
Mark Hamill	3	8.198246

Protagonista	Películas	Ingresos Generados Promedio Ajustados
Joe Russo	4	309647301
Daisy Ridley	1	241760246
Daniel Radcliffe	6	210804004

Con respecto al protagonista, se observa que en promedio los actores Elijah Wood, Tim Robbins y Mark Hamill se asocian, en promedio, a las mayores calificaciones en la plataforma IMDb. Por otro lado, son Joe Russo, Daisy Ridley y Daniel Radcliffe quienes están asociados en promedio al mayor éxito comercial.

Director	Películas	IMDb Promedio Ajustado
Christopher Nolan	8	8.290644
Frank Darabont	2	8.281288
Francis Ford Coppola	5	8.198636

Director	Películas	Ingresos Generados Promedio Ajustados
Anthony Russo	4	309647301
J.J. Abrams	3	242187130
James Cameron	5	224486178

Además, se observa que Christopher Nolan, Frank Darabont y Francis Ford Coppola son los directores que en promedio se asocian a una mayor calificación de IMDb. Con respecto al aspecto comercial, Anthony Russo, J. J. Abrams y James Cameron son los directores más exitosos en promedio.

Trama peliculas

En cuánto al análisis de trama se encontraron resultados interesentes. Para los pares de palabras que conjuntamente son más frecuentes, se pueden observar algunos patrones narrativos como: historias desarolladas durante las guerras mundiales, siendo más frecuentes narrativas ambientadas en la segunda; relatos de relaciones paternofiliales; narrativas que exploran encontrar el amor; historias basadas en la realidad, tipo biográficas; relacionadas con el crimen o la justicia, cómo acusaciones de homicidios e historias de índole agentes secretos. Cabe recalcar que estas relaciones solo analizan pares de palabras que son probables de ir juntas en diferentes peliculas y que independientemente no representan una cantidad significativa de las peliculas del dataset.

Par de palabras	Correlación	Películas	% Películas	IMDb	MetaScore
war + world	0.435	29	3.4	7.95	81.31
falls + love	0.446	12	1.4	7.92	80.08
father + son	0.242	8	0.9	7.89	76.88
accused + murder	0.303	5	0.6	7.84	70.80
agent + secret	0.279	5	0.6	7.90	82.40

Por otro lado las palabras (únicas) más frecuentes, filtradas por relevancia, apoyan los resultados de los pares en el apartado de historias de guerra, cuya palabra *war* por si sola se encuentra en 6 de las peliculas del dataset. Otras palabras con peso incluyen relaciones interpersonales cómo *friends* o de familia cómo: *son, family, father*; y de individuos *woman, boy, girl*. De nuevo hace falta mencionar que los resultados son limitados pues las palabras por si solas no revelan una narrativa, por lo que las interpretaciones pueden resultar especulativas y sesgadas, además que no pertenecen a una cantidad significativa de peliculas e incluso pueden aparecer juntas por lo que los porcentajes no son aditivos.

Palabra	Películas	% Películas	IMDb	MetaScore
family	48	5.7	7.88	77.92
woman	48	5.7	7.90	81.54
boy	37	4.4	7.91	73.57
son	31	3.7	8.04	76.45
friends	30	3.6	7.87	77.70
girl	29	3.4	7.97	79.48
father	28	3.3	7.89	78.14

En cuantó a las conclusiones que podemos realizar de este análisis exploratorio, podemos decir que en las tablas reportadas, el público general representado por la calificación imdb muestra tendencia hacia narrativas orientadas a la guerra, particularmente a las referidas con la segunda guerra mundial y de encontrar el amor, por otro lado la crítica especializada representada por meta score parece coincidir en que las historias de la segunda guerra mundial promedian mayor puntaje, así como una inclinación por relatos detectivescos o de agentes secretos.

Dadas las limitaciones, las conclusiones anteriores deben ser tomadas con reserva, pues en adición a las problemáticas presentadas, las cantidades de peliculas por palabras o palabra suelen variar y no ser proporcionales. Sin embargo si tenemos que extraer una narrativa con contundencia nos podemos decantar por las alusivas a la segunda guerra mundial o más general a la guerra pues son las que reunen mayor cantidad en porcentaje, y que a la vez promedian calificaciones destacadas.

Género

En la data encontramos que géneros cómo drama, `Comedy`, `Adventure` y `Crime` son los más ubicuos, con especial enfásis en drama que aparece en más del 71% de las peliculas de la lista. Por otro lado géneros cómo `Sport, Musical` y `Film Noir` son los menos frecuentes, con menos del 2% de presencia. En cuánto a intersecciones de géneros encontramos que los tres más frecuentes incluyen `Drama`, `Comedy, Drama` y `Drama, Romance` reforzando la idea de Drama cómo género central.

En cuánto a los distintos párametros encontramos en `resultados.generos` que en taquilla las peliculas que promedian más incluyen `Adventure`, `Sci-Fi` y `Action`, mientras que la crítica del público se orienta a peliculas cómo `Film-Noir`, `Western` y `War`, por otra parte la crítica especializada comparte preferencias por el `Film-Noir` y `Western`, además incluyen `Horror` en sus tres mejores calificados.

Para contrastar podemos ver las combinaciones en `res.interseccion` de géneros más presentes, en lo que composiciones cómo `Crime, Drama`, se repiten entre los mejores calificados (meta e imdb), aunque la crítica especializada y taquilla eligen en cómun `Animation, Adventure, Comedy` y `Drama, Romance` cómo los géneros de mayor éxito, además los mayores éxitos en taquilla lo recibe el género compuesto por `Accion, Adventure, Sci-Fi`. Asimismo también encontramos que el apartado crítica suele diferir más en los géneros `Action, Adventure, Sci-Fi`; `Crime, Drama, Thriller` y `Action, Crime, Drama`. La tendencia es que el público valora peliculas con estas características, en mayor medida que su contraparte especializada.

Géneros	Películas	IMDb	MetaScore	Dif. Crítica	Taquilla (mill.$)
Drama	71	7.94	78.01	0.14	30.46
Drama, Romance	32	7.93	82.69	−0.34	72.68
Comedy, Drama	29	7.84	80.07	−0.17	34.64
Crime, Drama, Thriller	25	7.92	74.24	0.50	52.33
Action, Crime, Drama	23	7.84	73.43	0.50	65.41
Biography, Drama, History	23	8.00	78.74	0.12	62.51
Comedy, Drama, Romance	23	7.85	76.74	0.17	39.42
Animation, Adventure, Comedy	23	7.93	83.30	−0.40	225.17
Crime, Drama	22	8.17	81.55	0.01	29.49
Action, Adventure, Sci-Fi	21	7.93	71.52	0.78	280.89
Crime, Drama, Mystery	21	7.89	74.14	0.48	38.47

En cuánto a los alcances del análisis observamos una discrepancia entre los géneros individuales que dominan en los párametros mencionados y la composición que observamos originalmente en el `df.original`, especialmente en el apartado crítica. Esto puede ocurrir por varias razones, en primer lugar los géneros individuales se pueden encontrar en varias categorias de peliculas lo que provoca que géneros como `Drama`, `Comedy`, `Adventure` y `Crime` que acumulan mayor volumen en la lista tengan un promedio más bajo pues abordan una gama amplia y variada de peliculas, en cambio otras con

una cantidad menor a 100, tengan un promedio más alto pues la categorias son más específicas. Por otro lado en taquilla no tenemos disparidad pues incluyen géneros blockbusters o peliculas de alto presupuesto que promedian grandes taquillas.

Además de lo anterior, encontramos otra diferencia en cuánto a lo analizado en sinópsis donde vimos que la palabra bélica en la descripción representaba una de las más habituales y de mayor éxito, mientras que en este apartado no aparecen entre las composiciones más habituales aunque tenga su propia etiqueta `War`. Una explicación plausible es que solo hay 45 peliculas con esta etiqueta en toda la lista lo que representa solo el 5.34% de esta, por lo que es muy poco frecuente, sin embargo esto no implica que el análisis de sinópsis haya sido mal planteado sino que la témática se materializa en otros géneros cómo `Drama`; `Biography`; `History`; `Thriller`, etc.

Podemos concluir de lo anterior que los géneros individuales pueden distorsionar el análisis por variabilidad en el número de peliculas y que la intersección entre géneros es más confiable pues son proporcionalmente semejantes y que aunque no sea explicíto en la etiqueta, la guerra está presente cómo ambientación o catalizador en las peliculas.

Bibliografía

Bache, S. M. y Wickham, H. (2022). *magrittr: A forward-pipe operator for R* (versión 2.0.3) [Paquete de R]. https://doi.org/10.32614/CRAN.package.magrittr

IMDb. (s.f.). *Apollo 13* (1995). Recuperado el 5 de noviembre de 2026, de https://www.imdb.com/title/tt0112384/

Kotal, A. (2022). *IMBD top 1000 with description* [Conjunto de datos]. Kaggle. https://doi.org/10.34740/kaggle/dsv/3954453

MetricGate. (2025). *Contracción de Bayes empírico* [Aplicación web]. https://metricgate.com/docs/es/empirical-bayes-shrinkage/

R Core Team. (2025). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing. https://www.R-project.org/

Robinson, D. y Silge, J. (2022). *widyr: Widen, process, then re-tidy data* (versión 0.1.5) [Paquete de R]. https://doi.org/10.32614/CRAN.package.widyr

Silge, J. y Robinson, D. (2016). tidytext: Text mining and analysis using tidy data principles in R. *Journal of Open Source Software*, *1*(3). https://doi.org/10.21105/joss.00037

Wickham, H. (2016). *ggplot2: Elegant graphics for data analysis*. Springer-Verlag New York. https://ggplot2.tidyverse.org

Wickham, H. (2023). *stringr: Simple, consistent wrappers for common string operations* (versión 1.5.1) [Paquete de R]. https://doi.org/10.32614/CRAN.package.stringr

Wickham, H., François, R., Henry, L., Müller, K. y Vaughan, D. (2023). *dplyr: A grammar of data manipulation* (versión 1.1.4) [Paquete de R]. https://doi.org/10.32614/CRAN.package.dplyr

Wickham, H. y Henry, L. (2025). *purrr: Functional programming tools* (versión 1.1.0) [Paquete de R]. https://doi.org/10.32614/CRAN.package.purrr

Wickham, H., Hester, J. y Bryan, J. (2024). *readr: Read rectangular text data* (versión 2.1.5) [Paquete de R]. https://doi.org/10.32614/CRAN.package.readr

Wickham, H., Vaughan, D. y Girlich, M. (2024). *tidyr: Tidy messy data* (versión 1.3.1) [Paquete de R]. https://doi.org/10.32614/CRAN.package.tidyr

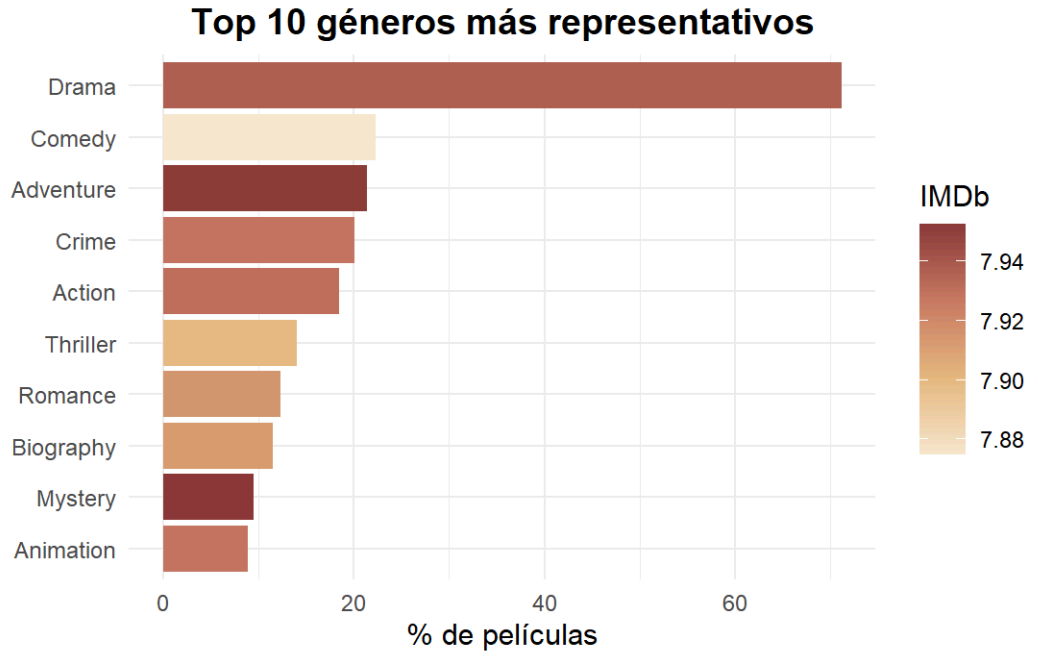
Xie, Y. (2025). *knitr: A general-purpose package for dynamic report generation in R* (versión 1.50) [Paquete de R]. https://yihui.org/knitr/

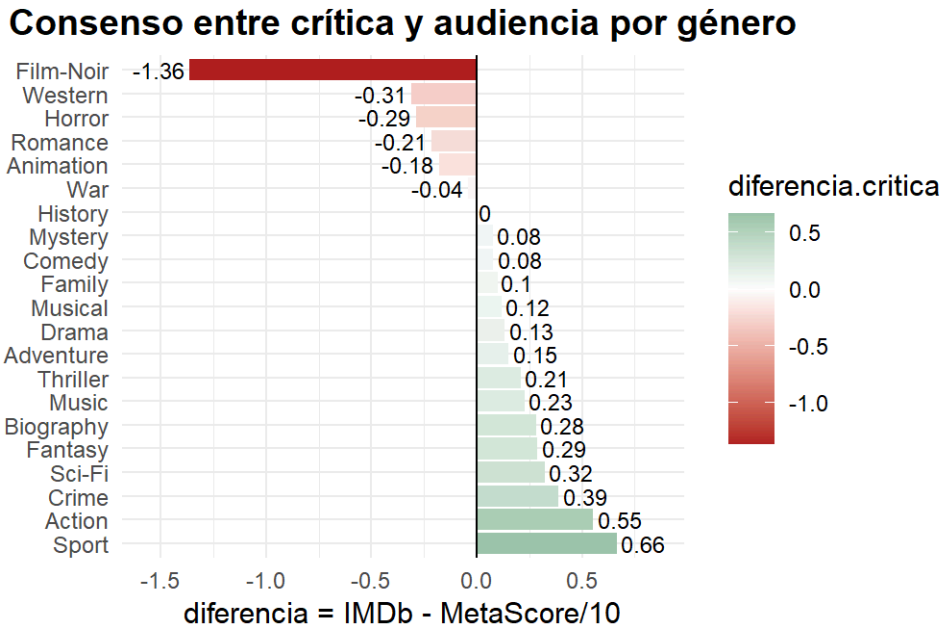
Anexos

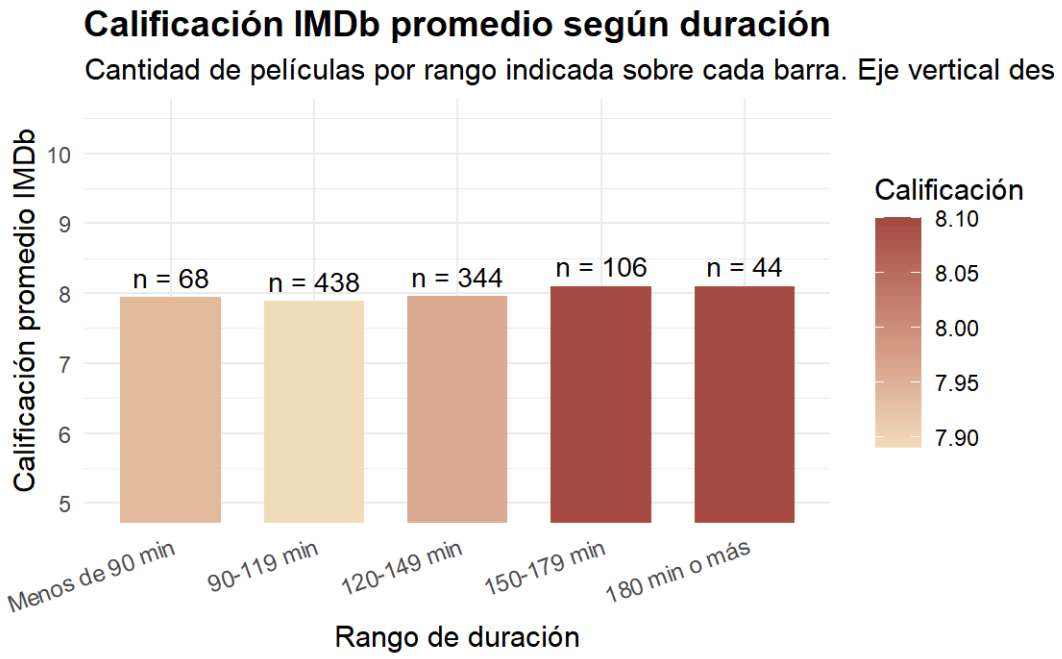
Repositorio del proyecto: https://github.com/corgab33/Proyecto-Grupal-CA0204

Genero	Pelicula	Genero	Pelicula	Genero	Pelicula
Drama	600	Biography	97	War	45
Comedy	188	Mystery	80	Music	38
Adventure	180	Animation	75	Horror	27
Crime	169	Sci-Fi	62	Western	20
Action	156	Fantasy	58	Sport	17
Thriller	118	Family	50	Musical	12
Romance	104	History	48	Film-Noir	11

Tabla 1: Representatividad de los géneros en peliculas







La duración marca una leve diferencia, y tomando en cuenta la cantidad de películas que pertenecen a los rangos de duración, notamos que son relativamente pocas las que que tienen una duración mayor a dos horas y media (150 minutos o más), pero en términos de promedios, si tienen una calificación más alta las peliculas con mayor duración.